Ana Ellen 2024-08-26 Lista Modelos ARCH: Teórica e Prática 1_ Considere o modelo ARCH(1) dado por: $r_t = \delta + \epsilon_t$ $\epsilon_t = \sigma_t z_t, \quad z_t \sim N(0,1)$ $\sigma_t^2 = \omega + lpha \epsilon_{t-1}^2$ onde $\omega > 0$ e $\alpha \geq 0$. Seja o conjunto de informação $I_{t-1} = \{r_1, r_2, \dots, r_{t-1}\}$. (a) Explique em palavras por que os parâmetros ω e α são restritos a serem positivo e não negativo, respectivamente. • ω : A variância precisa sempre assumir um valor positivo por ser uma medida de dispersão, e como ω atua como o valor mínimo que a variância pode assumir pela equação, este deve ser positivo. • α : Como α é a variável que acompanha os erros quadrados, se esta for negativa, existe chance da volatilidade se tornar negativa, o que não seria possível; já se α for 0, o valor da variânncia seria o valor mínimo, ω . Também porque, se α fosse negativo, grandes choque do passado diminuiriam muito a variância futura, o que não consiste como comportamento dos mercados financeiros. (b) Explique em palavras como o modelo acima permite clusters de volatilidade, que é um fato empírico estilizado de séries financeiras. • Como a variância condicional depende dos choques passados, se um grande choque ocorre em um certo período, ele aumenta a variância condicional do próximo, o que pode acabar levando a outro grande choque. Logo, os períodos de alta volatilidade tendem a ficar mais agrupados, permitindo clusters de volatilidade. (c) Cite dois fatos estilizados de séries temporais financeiras que não são capturados pelo modelo acima. • Efeito de alavancagem (bad news) • Caudas pesadas se a distribuição for Normal (captura se for t Student) (d) Explique em palavras a diferença entre variância condicional e incondicional. Enquanto a **condicional** é a variância prevista para um dado período, considerando informações já disponíveis, a incondicional é a variância média ao longo de todo o período e não muda ao longo do tempo. 2-Descreva como as FAC e FACP são utilizadas no contexto de modelos da família ARCH. Em quais etapas do ajuste do modelo elas são úteis? • Utilidade: Para checar a heterocedasticidade condicional - FAC e FACP são aplicadas nos resíduos ao quadrado da equação da média ou na série de retornos ao quadrado - são usadas para checar a heterocedasticidade condicional. • Etapas: São usadas antes do ajuste do modelo, para identificar a ordem e para fazer o diagno´stico do modelo. 3-Ajuste os modelos da família ARCH vistos em aula, considerando a ordem (1,1) com as distribuições normal e t-Student para as seguintes séries, iniciando em 2019: library(rugarch) ## Carregando pacotes exigidos: parallel ## ## Anexando pacote: 'rugarch' ## O seguinte objeto é mascarado por 'package:stats': ## ## sigma library(quantmod) ## Carregando pacotes exigidos: xts ## Carregando pacotes exigidos: zoo ## ## Anexando pacote: 'zoo' ## Os seguintes objetos são mascarados por 'package:base': ## ## as.Date, as.Date.numeric ## Carregando pacotes exigidos: TTR ## Registered S3 method overwritten by 'quantmod': ## method ## as.zoo.data.frame zoo getSymbols("PETR4.SA", from="2019-01-01", to=Sys.Date()) ## [1] "PETR4.SA" getSymbols("^BVSP", from="2019-01-01", to=Sys.Date()) ## [1] "BVSP" ret_petrobras <- dailyReturn(Cl(PETR4.SA), type = 'log')</pre> ret_ibovespa <- dailyReturn(Cl(BVSP), type = 'log')</pre> # Especificar o modelo ARCH(1) com distribuição normal spec_norm <- ugarchspec(variance.model = list(model = "sGARCH", garchOrder = c(1,1)),</pre> mean.model = list(armaOrder = c(0,0)),distribution.model = "norm") # Especificar o modelo ARCH(1) com distribuição t-Student spec_t <- ugarchspec(variance.model = list(model = "sGARCH", garchOrder = c(1,1)),</pre> mean.model = list(armaOrder = c(0,0)),distribution.model = "std") (a) Log-retornos diários das ações da PETROBRAS # Ajustar o modelo para Petrobras fit_petro_norm <- ugarchfit(spec = spec_norm, data = ret_petrobras)</pre> # Ajustar o modelo para Petrobras fit_petro_t <- ugarchfit(spec = spec_t, data = ret_petrobras)</pre> fit_petro_norm ## ## * GARCH Model Fit ## *----* ## ## Conditional Variance Dynamics ## -----## GARCH Model : sGARCH(1,1) ## Mean Model : ARFIMA(0,0,0)## Distribution : norm ## ## Optimal Parameters Estimate Std. Error t value Pr(>|t|)## ## mu 0.000830 0.000604 1.3730 0.169762 ## omega 0.000059 0.000021 2.8061 0.005014 ## alpha1 0.157866 0.029813 5.2951 0.000000 ## beta1 0.772253 0.050880 15.1780 0.000000 ## ## Robust Standard Errors: Estimate Std. Error t value Pr(>|t|) ## ## mu 0.000830 0.000736 1.12735 0.259594 ## omega 0.000059 0.000067 0.88049 0.378593 ## alpha1 0.157866 0.119961 1.31597 0.188182 ## beta1 0.772253 0.185806 4.15623 0.000032 ## ## LogLikelihood: 3203.027 ## ## Information Criteria ## ## ## Akaike -4.5538 ## Bayes -4.5388 -4.5538 ## Shibata ## Hannan-Quinn -4.5482 ## ## Weighted Ljung-Box Test on Standardized Residuals -----## statistic p-value 0.1229 0.7259 ## Lag[1] ## Lag[2*(p+q)+(p+q)-1][2] 0.5557 0.6680 ## Lag[4*(p+q)+(p+q)-1][5] 2.1185 0.5907 ## d.o.f=0 ## H0 : No serial correlation ## ## Weighted Ljung-Box Test on Standardized Squared Residuals ## -----## statistic p-value ## Lag[1] 0.7668 0.3812 ## Lag[2*(p+q)+(p+q)-1][5] 1.7129 0.6876 ## Lag[4*(p+q)+(p+q)-1][9] 3.7382 0.6335 ## d.o.f=2 ## ## Weighted ARCH LM Tests ## ## Statistic Shape Scale P-Value ## ARCH Lag[3] 0.4456 0.500 2.000 0.5044 0.7949 1.440 1.667 0.7946 ## ARCH Lag[5] ## ARCH Lag[7] 1.1868 2.315 1.543 0.8814 ## Nyblom stability test ## -----## Joint Statistic: 0.9785 ## Individual Statistics: 0.08513 ## mu ## omega 0.39006 ## alpha1 0.10864 ## beta1 0.25018 ## ## Asymptotic Critical Values (10% 5% 1%) ## Joint Statistic: 1.07 1.24 1.6 ## Individual Statistic: 0.35 0.47 0.75 ## ## Sign Bias Test ## ----t-value prob sig ## 0.4436 0.65738 ## Sign Bias ## Negative Sign Bias 2.2660 0.02360 ## Positive Sign Bias 0.5700 0.56876 ## Joint Effect 10.1643 0.01722 ## ## ## Adjusted Pearson Goodness-of-Fit Test: ## ----group statistic p-value(g-1) 7.573e-12 ## **1** 93.6 20 ## 2 30 106.0 1.034e-10 ## 3 40 123.8 9.359e-11 ## 2 ## 4 50 146.1 1.344e-11 ## ## Elapsed time : 0.1246159 fit_petro_t ## GARCH Model Fit ## * ## *----* ## Conditional Variance Dynamics ## -----## GARCH Model : sGARCH(1,1) ## Mean Model : ARFIMA(0,0,0)## Distribution : std ## ## Optimal Parameters ## -----## Estimate Std. Error t value Pr(>|t|)## mu 0.001492 0.000521 2.8644 0.004178 ## omega 0.000030 0.000011 2.6958 0.007022 ## alpha1 0.066205 0.018741 3.5326 0.000412 ## beta1 0.891466 0.028434 31.3516 0.000000 ## shape 3.871101 0.409899 9.4440 0.000000 ## ## Robust Standard Errors: ## Estimate Std. Error t value Pr(>|t|)## mu 0.001492 0.000473 3.1521 0.001621 ## omega 0.000030 0.000015 1.9561 0.050450 ## alpha1 0.066205 0.032159 2.0587 0.039523 0.891466 0.044302 20.1224 0.000000 ## beta1 3.871101 0.408499 9.4764 0.000000 ## shape ## ## LogLikelihood : 3326.357 ## ## Information Criteria ## -----## ## Akaike -4.7279 ## Bayes -4.7092 -4.7279 ## Shibata ## Hannan-Quinn -4.7209 ## ## Weighted Ljung-Box Test on Standardized Residuals ## -----## statistic p-value ## Lag[1] 0.1538 0.6949 ## Lag[2*(p+q)+(p+q)-1][2] 0.4766 0.7047 ## Lag[4*(p+q)+(p+q)-1][5] 1.6545 0.7019 ## d.o.f=0 ## H0 : No serial correlation ## ## Weighted Ljung-Box Test on Standardized Squared Residuals ## statistic p-value ## Lag[1] 6.163 0.01305 ## Lag[2*(p+q)+(p+q)-1][5] 6.328 0.07521 ## Lag[4*(p+q)+(p+q)-1][9] 9.759 0.05645 ## d.o.f=2 ## ## Weighted ARCH LM Tests ## -----Statistic Shape Scale P-Value ## ## ARCH Lag[3] 0.2499 0.500 2.000 0.6171 ## ARCH Lag[5] 0.2748 1.440 1.667 0.9469 ## ARCH Lag[7] 0.6470 2.315 1.543 0.9632 ## ## Nyblom stability test ## -----## Joint Statistic: 1.8834 ## Individual Statistics: ## mu 0.1124 ## omega 0.4107 ## alpha1 0.4232 ## beta1 0.2982 ## shape 0.4586 ## ## Asymptotic Critical Values (10% 5% 1%) ## Joint Statistic: 1.28 1.47 1.88 ## Individual Statistic: 0.35 0.47 0.75 ## ## Sign Bias Test ## -----## prob sig t-value ## Sign Bias 0.1212 9.035e-01 ## Negative Sign Bias 4.2257 2.537e-05 *** ## Positive Sign Bias 0.0444 9.646e-01 ## Joint Effect 22.0492 6.371e-05 *** ## ## ## Adjusted Pearson Goodness-of-Fit Test: ## ----group statistic p-value(g-1) ## ## 1 20 15.03 0.7208 ## 2 30 27.51 0.5445 0.8357 30.42 ## 3 40 ## 4 50 53.19 0.3162 ## ## ## Elapsed time : 0.1586082 (b) Log-retornos diários do IBOVESPA # Ajustar o modelo para Ibovespa fit_ibov_norm <- ugarchfit(spec = spec_norm, data = ret_ibovespa)</pre> # Ajustar o modelo para Ibovespa fit_ibov_t <- ugarchfit(spec = spec_t, data = ret_ibovespa)</pre> fit_ibov_norm ## ## *----* GARCH Model Fit * ## * ## *----* ## ## Conditional Variance Dynamics ## -----## GARCH Model : sGARCH(1,1) ## Mean Model : ARFIMA(0,0,0)## Distribution : norm ## ## Optimal Parameters ## ## Estimate Std. Error t value Pr(>|t|)0.000541 0.000308 1.75743 0.078845 ## mu ## omega 0.000004 0.000005 0.87727 0.380340 ## alpha1 0.089475 0.013917 6.42927 0.000000 ## beta1 0.887160 0.022890 38.75796 0.000000 ## ## Robust Standard Errors: Estimate Std. Error t value Pr(>|t|) ## ## mu 0.000541 0.000312 1.73041 0.083557 ## omega 0.000004 0.000026 0.17174 0.863638 ## alpha1 0.089475 0.039875 2.24388 0.024840 ## beta1 0.887160 0.094552 9.38275 0.000000 ## ## LogLikelihood : 4150.505 ## ## Information Criteria -----## ## Akaike -5.9025 ## Bayes -5.8876 ## Shibata -5.9025 ## Hannan-Quinn -5.8969 ## ## Weighted Ljung-Box Test on Standardized Residuals ## ## statistic p-value 1.509 0.2192 ## Lag[1] ## Lag[2*(p+q)+(p+q)-1][2] 1.619 0.3345 ## Lag[4*(p+q)+(p+q)-1][5] 2.655 0.4737 ## d.o.f=0 ## H0 : No serial correlation ## ## Weighted Ljung-Box Test on Standardized Squared Residuals ## -----## statistic p-value 0.151 0.6976 ## Lag[1] 1.975 0.6242 ## Lag[2*(p+q)+(p+q)-1][5] ## Lag[4*(p+q)+(p+q)-1][9] 6.463 0.2485 ## d.o.f=2 ## ## Weighted ARCH LM Tests ## -----## Statistic Shape Scale P-Value ## ARCH Lag[3] 2.351 0.500 2.000 0.1252 ## ARCH Lag[5] 2.592 1.440 1.667 0.3547 3.232 2.315 1.543 0.4709 ## ARCH Lag[7] ## ## Nyblom stability test ## -----## Joint Statistic: 1.143 ## Individual Statistics: ## mu 0.07953 ## omega 0.32993 ## alpha1 0.41723 ## beta1 0.28822 ## Asymptotic Critical Values (10% 5% 1%) ## Joint Statistic: 1.07 1.24 1.6 ## Individual Statistic: 0.35 0.47 0.75 ## ## Sign Bias Test ## -----## t-value prob sig ## Sign Bias 1.2857 0.19874 ## Negative Sign Bias 1.3079 0.19112 ## Positive Sign Bias 0.5836 0.55962 ## Joint Effect 6.2854 0.09852 ## ## ## Adjusted Pearson Goodness-of-Fit Test: ## -----## group statistic p-value(g-1) ## 1 20 27.90 0.08544 30 40.96 ## 2 0.06946 40 55.53 50 77.38 ## 3 0.04173 ## 4 0.00599 ## ## ## Elapsed time : 0.1026399 fit_ibov_t ## ## *----* ## * GARCH Model Fit ## *----* ## ## Conditional Variance Dynamics -----## GARCH Model : sGARCH(1,1) ## Mean Model : ARFIMA(0,0,0)## Distribution : std ## ## Optimal Parameters Estimate Std. Error t value Pr(>|t|)## ## mu ## omega 0.000004 0.000003 1.4571 0.145079 ## alpha1 0.081398 0.015423 5.2776 0.000000 ## beta1 0.893442 0.018213 49.0540 0.000000 ## shape 9.568586 2.018920 4.7395 0.000002 ## ## Robust Standard Errors: ## Estimate Std. Error t value Pr(>|t|)## mu ## omega 0.000004 0.000008 0.59233 0.553629 ## alpha1 0.081398 0.026968 3.01838 0.002541 ## beta1 0.893442 0.029930 29.85061 0.000000 ## shape 9.568586 2.426171 3.94390 0.000080 ## ## LogLikelihood : 4170.834 ## ## Information Criteria ## -----## -5.9300 ## Akaike ## Bayes -5.9113 ## Shibata -5.9300 ## Hannan-Quinn -5.9230 ## ## Weighted Ljung-Box Test on Standardized Residuals ## ----statistic p-value ## 1.550 0.2131 ## Lag[1] 1.645 0.3291 ## Lag[2*(p+q)+(p+q)-1][2] ## Lag[4*(p+q)+(p+q)-1][5] 2.647 0.4753 ## d.o.f=0 ## H0 : No serial correlation ## Weighted Ljung-Box Test on Standardized Squared Residuals ## -----## statistic p-value 0.02016 0.8871 ## Lag[1] ## Lag[2*(p+q)+(p+q)-1][5] 2.68607 0.4674 ## Lag[4*(p+q)+(p+q)-1][9] 8.11868 0.1222 ## d.o.f=2 ## ## Weighted ARCH LM Tests ## -----Statistic Shape Scale P-Value ## ARCH Lag[3] 3.346 0.500 2.000 0.06735 ## ARCH Lag[5] 3.490 1.440 1.667 0.22621 4.332 2.315 1.543 0.30116 ## ARCH Lag[7] ## ## Nyblom stability test ## -----## Joint Statistic: 1.6059 ## Individual Statistics: ## mu 0.1982 ## omega 0.1239 ## alpha1 0.3441 ## beta1 0.2383 ## shape 0.1785 ## Asymptotic Critical Values (10% 5% 1%) ## Joint Statistic: 1.28 1.47 1.88 ## Individual Statistic: 0.35 0.47 0.75 ## ## Sign Bias Test ## ----t-value prob sig ## ## Sign Bias 1.1489 0.25079 ## Negative Sign Bias 1.6195 0.10556 ## Positive Sign Bias 0.7242 0.46907 ## Joint Effect 6.9603 0.07317 ## ## ## Adjusted Pearson Goodness-of-Fit Test: ## ----group statistic p-value(g-1) ## 0.08377 27.98 ## 1 20 30 38.18 ## 2 0.11835 ## 3 40 53.59 0.05993 50 62.01 0.10041 ## 4 ## ## ## Elapsed time : 0.1333451 4-Para os modelos ajustados acima, calcule os coeficientes de persistência e half-life e interprete os resultados. # Calcular coeficiente de persistência e half-life para Petrobras alpha_petro <- coef(fit_petro_norm)["alpha1"]</pre> beta_petro <- coef(fit_petro_norm)["beta1"]</pre> persistencia_petro <- alpha_petro + beta_petro</pre> $half_life_petro <- log(0.5) / log(persistencia_petro)$ # Exibir resultados para Petrobras persistencia_petro ## alpha1 ## 0.9301186 half_life_petro ## alpha1 ## 9.568145 # Calcular coeficiente de persistência e half-life para Petrobras alpha_petro <- coef(fit_petro_t)["alpha1"]</pre> beta_petro <- coef(fit_petro_t)["beta1"]</pre> persistencia_petro <- alpha_petro + beta_petro</pre> half_life_petro <- log(0.5) / log(persistencia_petro) # Exibir resultados para Petrobras persistencia_petro alpha1 ## 0.9576717 half_life_petro alpha1 ## ## 16.02644 Petrobras: Normal | A persistência da volatilidade é alta (0,93), e o choque leva cerca de 9,57 períodos para se dissipar pela metade. t Student | A persistência é ligeiramente maior (0,96), com um half-life mais longo, de 16,03 períodos, indicando choques mais duradouros. # Calcular coeficiente de persistência e half-life para Ibovespa alpha_ibov <- coef(fit_ibov_norm)["alpha1"]</pre> beta_ibov <- coef(fit_ibov_norm)["beta1"]</pre> persistencia_ibov <- alpha_ibov + beta_ibov</pre> half_life_ibov <- log(0.5) / log(persistencia_ibov) # Exibir resultados para Ibovespa persistencia_ibov

##

##

##

alpha1

0.9766347

half life ibov

alpha1 ## 29.31771

persistencia_ibov

alpha1

0.9748408

half_life_ibov

alpha1 ## 27.2024

Ibovespa:

tempo para se dissipar.

duração dos choques.

Calcular coeficiente de persistência e half-life para Ibovespa

Normal | A volatilidade é muito persistente (0,98), com um half-life de 29,32 períodos, sugerindo que os choques levam bastante

t Student | A persistência é quase igual (0,97), com um half-life um pouco menor (27,20 períodos), mas ainda indica uma longa

alpha_ibov <- coef(fit_ibov_t)["alpha1"]</pre> beta_ibov <- coef(fit_ibov_t)["beta1"]</pre>

Exibir resultados para Ibovespa

persistencia_ibov <- alpha_ibov + beta_ibov</pre>

half_life_ibov <- log(0.5) / log(persistencia_ibov)